

Contents

全天候指数仓位择时框架（一） 1

 贝叶斯在线变点检测与久期感知状态机——以中证 800 为例 1

 一、引言与研究背景 1

 二、数据与特征构建 2

 三、理论基础 3

 四、模型构建与逐步优化路径（Baseline → Final） 5

 五、工程实现与推理流程 6

 六、回测框架与统计检验 7

 七、客户应用 8

 八、总结与展望 8

 九、风险提示 8

全天候指数仓位择时框架（一）

贝叶斯在线变点检测与久期感知状态机——以中证 800 为例

- 核心思想：本文构建一套全天候、事件驱动（不设固定调仓频次）的指数仓位择时框架。其方法论内核是一个贝叶斯概率状态机——以贝叶斯在线变点检测（BOCPD）严格因果地识别市场区制断点，叠加隐半马尔可夫模型（HSMM）的显式久期建模，将“当前所处区制 + 区制已存续时长 + 预期剩余久期 + 后验不确定性”联合映射为连续仓位。
- 模型属性界定：本框架核心为概率图模型 / 贝叶斯序贯推断，属机器学习的概率统计分支，非深度学习、非强化学习。深度学习仅作为可选的轻量“后验 → 仓位”映射头出现（可由单调参数函数替代）；强化学习不在本框架内，仅作为可选超结构（另文讨论）。
- 边际贡献：相较于业界主流的离线 HMM 择时，本框架在三个维度上形成差异化——(1) 严格因果、在线滤波，结构上规避前视偏差；(2) 以 HSMM 显式久期替代 HMM 隐含的几何久期假设，刻画“区制会变老”的真实统计规律，并据此构造“预期剩余久期”信号以应对趋势末端风险；(3) 映射全 run-length 后验（而非仅 MAP 状态）至连续仓位，叠加无交易带实现换手可控的事件驱动调仓。
- 优化路径：本文给出从基线（Baseline）到终版模型的五级消融式优化路径，逐级隔离“信息增益、结构增益、自适应增益、稳健性增益”，每一级须在样本外独立稳健才予保留。
- 数据可行性：全框架仅依赖日频指数量价（可选叠加市场宽度），不依赖文本情感或日内高频数据，工程落地门槛低、可解释、可审计。
- 双客户价值：量化客户取连续仓位信号；基金研究客户取“区制识别 + 久期 + 切换告警”的市场状态叙事。
- 风险提示：模型基于历史统计规律构建，存在区制识别滞后、参数误设、结构性失效等风险；本文为方法论研究，不构成任何投资建议。详见文末。

一、引言与研究背景

1.1 指数择时的核心困难

指数仓位择时的本质，是对市场系统性风险敞口进行动态管理。其困难根植于三点：其一，信噪比极低，指数收益的可预测成分微弱且不稳定；其二，区制切换（**regime shift**）使得任一固定信号的有效性随市场状态漂移（如动量在趋势市有效、在震荡市失效）；其三，也是最隐蔽的——前视偏差（**look-ahead bias**）陷阱：大量择时回测在区制识别环节不慎引入了未来信息，导致样本内绩效虚高而样本外迅速衰减。

1.2 现有方法与边际贡献


区制择时的经典工具为隐马尔可夫模型(HMM)。然而实务中 HMM 择时常以离线平滑(**smoothed**)方式运行——即用全样本估计参数并以 **Viterbi** / 前向后向给出状态——这一做法在回测中隐含使用了未来信息，是前视偏差的高发区。此外，HMM 对状态久期的刻画为隐含的几何分布，与“牛市倾向于持续、危机倾向于短促”的经验事实相悖。

本文的边际贡献在于：以贝叶斯在线变点检测（**BOCPD**）替代离线 HMM，使区制识别严格因果、逐日在线，从结构上杜绝前视；以隐半马尔可夫（**HSMM**）的显式久期分布修正几何久期假设，并衍生“预期剩余久期”信号；以全后验映射 + 无交易带实现事件驱动、换手可控的连续仓位管理。

1.3 框架总览

本框架自下而上分三层（图表 1）：L1 由 **BOCPD** 维护 **run-length** 后验，因果识别变点；L2 由 **HSMM** 提供区制身份软分配与久期信息；L3 由贝叶斯决策将联合后验映射为连续仓位，经无交易带过滤后由事件触发调仓。逐指数/行业并行运行，顶层以风险预算实现差异化配置。

图表 1：框架三层结构（自下而上、严格因果流动）



二、数据与特征构建

标的：中证 800 指数（建议采用全收益口径，纳入分红再投资）。

样本区间与频率：日频；建议覆盖 10 年以上（中证 800 自 2007 年发布，可用区间充足），以确保 HSMM 久期分布能跨越多轮完整牛熊周期得到稳健估计。

特征构建（对应实现 `preprocess()`）：

1. 对数收益： $r_t = \ln(P_t/P_{t-1})$ 。采用收益而非价格，以获得可比与近似平稳的输入。

2. 已实现波动： $\sigma_t = \text{std}(r_{t-w+1:t})$, $w = 20$ 。波动是危机区制的核心识别线索（暴跌伴随波动飙升）。
3. 波动归一化收益： $z_t = r_t / \sigma_t$ 。归一化抑制条件异方差，使发射分布更接近平稳，提升状态识别稳定性。引擎实际“发射观测”即为 z_t （多维版可取 $[z_t, \sigma_t]$ 联合建模）。

数据约束说明：全框架仅需指数自身量价；如需增强可叠加市场宽度（成分股站上均线比例、涨跌家数、平均两两相关、截面离散度）。不依赖新闻文本情感，亦不依赖日内高频数据。

三、理论基础

本节系统梳理框架所依赖的理论，对关键概念给出定义与推导。

3.1 贝叶斯序贯推断

贝叶斯推断以“先验—似然—后验”的更新刻画在新证据下信念的修正：

$$\underbrace{p(\theta | x)}_{\text{后验}} \propto \underbrace{p(x | \theta)}_{\text{似然}} \underbrace{p(\theta)}_{\text{先验}}.$$

在序贯（在线）设定下， t 时刻的后验作为 $t+1$ 时刻的先验递归更新，天然契合“逐日来数据、逐日更新状态判断”的择时场景，且仅使用截至当前的信息，因果性由构造保证。

3.2 贝叶斯在线变点检测（BOCPD）

定义：贝叶斯在线变点检测（Bayesian Online Changepoint Detection, Adams & MacKay, 2007）是一种在线、因果的概率方法，用于实时推断时间序列的结构断点。其核心隐变量为 **run-length**（段龄） $r_t \in \{0, 1, 2, \dots\}$ ，表示“距上一变点已历经的步数”； $r_t = 0$ 即 t 时刻发生变点。

递归：记观测序列 $x_{1:t}$ ，段内预测模型（Underlying Predictive Model, UPM）给出预测概率 $\pi_t^{(r)} = p(x_t | r_{t-1}=r, x_{(t-r):t-1})$ 。则联合分布按下式递归：

- 段延续（run-length 增长）：

$$P(r_t=r+1, x_{1:t}) = P(r_{t-1}=r, x_{1:t-1}) \pi_t^{(r)} (1 - H(r+1));$$

- 段重置（发生变点）：

$$P(r_t=0, x_{1:t}) = \sum_r P(r_{t-1}=r, x_{1:t-1}) \pi_t^{(r)} H(r+1);$$

- 归一化得后验： $P(r_t | x_{1:t}) = P(r_t, x_{1:t}) / \sum_{r_t} P(r_t, x_{1:t})$ 。

其中 $H(\cdot)$ 为 **hazard** 函数（见 3.5）。该递归为精确（共轭发射下闭式）、在线（一遍前向）、严格因果（不涉及 t 之后信息）。

择时含义： $P(r_t=0 | x_{1:t})$ 即“当前发生区制断点”的后验概率，构成事件驱动调仓的触发量之一；run-length 后验的期望或 MAP 给出“当前区制已存续多久”。相对离线 HMM，BOCPD 的因果性是其规避前视偏差的结构性优势。

3.3 共轭发射与 Student-t 预测分布

为使 3.2 的预测概率 $\pi_t^{(r)}$ 可闭式计算，段内发射取共轭指数族。以单变量高斯发射、未知均值方差为例，采用 Normal-Inverse-Gamma (NIG) 共轭先验 $(\mu_0, \kappa_0, \alpha_0, \beta_0)$ 。观测 n 点、样本均值 $\bar{x}$ 、离差平方和 $S = \sum (x_i - \bar{x})^2$ 后，后验超参为：

$$\kappa_n = \kappa_0 + n, \quad \mu_n = \frac{\kappa_0 \mu_0 + n \bar{x}}{\kappa_n}, \quad \alpha_n = \alpha_0 + \frac{n}{2}, \quad \beta_n = \beta_0 + \frac{1}{2} S + \frac{\kappa_0 n (\bar{x} - \mu_0)^2}{2 \kappa_n};$$

后验预测分布为 **Student-t**:

$$x_t \sim t_{2\alpha_n} \left(\mu_n, \frac{\beta_n (\kappa_n + 1)}{\alpha_n \kappa_n} \right).$$

充分统计量按 run-length 并行递归更新，单步 $O(1)$ 摊还。多变量情形（如收益与波动联合）取 Normal-Inverse-Wishart (NIW) 共轭，后验预测为多元 Student-t。

金融意义：**Student-t** 较正态具有更厚的尾部，承认极端收益（尾部事件）的非可忽略概率，对暴跌更稳健。建议在波动归一化收益上建模，或直接采用 **Student-t** 发射进一步增强尾部稳健性。

3.4 隐马尔可夫 (HMM) 与隐半马尔可夫 (HSMM)

HMM 刻画系统在若干隐藏状态间的马尔可夫跳转。其结构性缺陷在于：状态自转移概率 a_{ii} 隐含状态久期服从几何分布——停留恰好 d 步的概率为 $a_{ii}^{d-1}(1 - a_{ii})$ ，期望久期 $1/(1 - a_{ii})$ 。几何分布无记忆、峰值在 $d=1$ ，意味着“任何区制都以‘下一步即结束’为最可能”，与市场经验严重不符。

HSMM (隐半马尔可夫) 的关键推广是：为每个状态 k 显式赋予久期分布 $g_k(d)$ ，状态进入后按 g_k 抽取停留时长 d ，发射 d 个观测后再转移。由此可刻画“牛市久期分布峰值在数百日、危机久期短促”等真实规律。其推断由前向后向算法的久期推广 (EDHMM) 完成，学习以 EM (Baum-Welch 推广) 或贝叶斯非参 (HDP-HSMM) 实现。

3.5 久期建模、hazard 函数与预期剩余久期

HSMM 久期与 **hazard** 的衔接：BOCPD 的 hazard $H(r)$ 可由久期分布 $g(\cdot)$ 导出，即段已存续至 $r-1$ 、恰在年龄 r 结束的条件概率：

$$H(r) = \frac{g(r)}{S(r-1)}, \quad S(r-1) = \sum_{d \geq r} g(d).$$

取非几何久期（如 Negative-Binomial）即令 hazard 随段龄合理变化——这正是将 **HSMM** 的久期信息注入 **BOCPD** 的数学通道，二者由此缝合为一个“在线显式久期变点模型”。

预期剩余久期：给定当前段龄 r 与区制 k ,

$$\mathbb{E}[\text{剩余} \mid \text{年龄}=r, z=k] = \frac{\sum_{d > r} (d - r) g_k(d)}{S_k(r)}.$$

此量将“趋势越老越脆弱”形式化：在有利区制中随预期剩余久期收缩而逐步降仓，在风险区制中随段龄上升而预防性去险。

3.6 区制识别与软分配

设 K 个区制原型（可由经济含义固定，如牛/震荡/回调/危机；或由段级发射统计无监督聚类得到）。在线时，将 **run-length** 后验加权的发射描述子 $[\hat{\mu}_t, \hat{\sigma}_t]$ 按距离做 **softmax** 软分配，得区制后验 $\{P(z=k | x_{1:t})\}$ 。每个区制配自身久期分布 g_k 与目标暴露 w_k^* 。

3.7 贝叶斯决策与仓位映射

由贝叶斯决策论，最优仓位为后验期望意义下的最优暴露。本文采用如下可解释映射：

$$w_t = \underbrace{\sum_k P(z=k | x_{1:t}) w_k^*}_{\text{区制混合暴露}} \times \underbrace{\phi(\mathbb{E}[\text{剩余} | \cdot])}_{\text{久期折减}} \times \underbrace{\psi(\mathcal{H}_t)}_{\text{不确定性收缩}},$$

其中 w_k^* 可由区制条件夏普或区制条件（分数）凯利标定； ϕ 为久期单调折减； ψ 随 **run-length** 后验熵 $\mathcal{H}_t$ 增大而收向中性仓（不确定即减小敞口偏离，思想与分数凯利一致）。若以可选 **MLP** 实现 f ，须施加单调性约束，且其为全框架唯一的（可选）深度学习组件。

四、模型构建与逐步优化路径（**Baseline** → **Final**）

4.1 消融式优化哲学

本文坚持“逐层隔离增益来源、每步独立验证”的构建纪律：**Step** 不是简单叠加，而是依次验证信息增益 → 结构增益 → 自适应增益 → 稳健性增益。任一步若不能在样本外独立稳健地提升绩效，即予剪枝，杜绝为复杂度而堆叠。下表给出五级路径（图表 2）。

图表2：基线到终版的五级优化路径

级别	模型设定	隔离的增益	可上线
S0	基线：恒定暴露 / 均线择时	—（基准）	✓
S1	离线 HMM（平滑，含前视）	信息：区制是否有用	✗（仅参照上界）
S2	因果 BOCPD，MAP→离散仓位	因果：去前视后的真值	✓
S3	全后验→连续仓位 + 无交易带	结构：概率化+平滑	✓
S4	HSMM 久期升级（年龄相依hazard+剩余）	自适应：久期感知	✓
S5	多指数/行业并行 + 稳健性检验	稳健：泛化与可推广	✓

4.2 各级详解

S0 · 基线（Baseline） 设定恒定满仓或经典均线择时为基准。意义在于设定“及格线”——后续任一增项须超越之，方证其价值。

S1 · 离线 HMM（前视上界参照）以全样本估计的两/多状态 HMM、平滑状态序列驱动仓位。该版本隐含使用未来信息，不可上线，仅作“区制信息理论上界”的参照。其与 S2 的绩效落差，即量化了前视偏差的幅度——这是本框架“严格因果”主张的实证支点。

S2 · 因果 BOCPD（首个可上线版）将 S1 替换为严格因果的 BOCPD，以 MAP **run-length** / 区制给出离散仓位。理论动机：在线滤波规避前视。验证：在因果约束下，S2 应显著优于“同样退化为因果模式的 HMM”，并量化 S1→S2 的前视折损。

S3 · 全后验映射 + 无交易带 不再以 **MAP** 硬切，而是将完整 **run-length** / 区制后验映射为连续仓位，叠加无交易带 δ 。理论动机：保留不确定性信息、平滑敞口、抑制噪声触发。验证：夏普提升且换手显著下降。

S4 · **HSMM** 久期升级（终版核心）将恒定 **hazard** 替换为 **HSMM** 久期导出的年龄相依 **hazard**，并将“预期剩余久期”纳入映射（对应实现 **BOCPD(duration=...)**）。理论动机：修正几何久期假设、刻画趋势末端脆弱性。验证：在区制末端/动量崩盘段，最大回撤与尾部损失进一步压低。

S5 · 多指数推广与稳健性 将引擎并行于多宽基/行业，顶层以风险预算分配；并在不同标的、不同时间窗、不同随机种子下复算。理论动机：验证绩效源于机制而非特定样本的偶然。验证：跨标的/跨窗口稳定为正且通过统计去伪（见六）。

终版模型 = **S2**（因果）+ **S3**（全后验/无交易带）+ **S4**（**HSMM** 久期）经 **S5** 推广与检验。**S1** 永远只作参照，不进入生产。

五、工程实现与推理流程

本框架在工程上严格区分离线估参与在线推理两阶段（对应实现 **run_engine()**）。

5.1 离线估参（建议季度滚动一次，严格因果窗口）

1. 发射先验：以历史 **z** 矩匹配标定 **NIG/NIW** 超参。
2. 久期分布：粗扫历史估平均段长，标定 **Negative-Binomial** 久期参数，导出年龄相依 **hazard** 与预期剩余久期。
3. 区制原型：对滚动 $[\bar{r}, \sigma]$ 聚类（如 **KMeans**）定 **K** 个区制，按区制条件夏普标定目标暴露 w_k^* 。

估参窗口须严格前向滚动，仅使用估计时点之前的数据。

5.2 在线推理（每个交易日收盘后，单步递归）

接收新 $z_t \rightarrow$ **BOCPD** 递归更新 **run-length** 后验（变点概率、段龄 **MAP**） $\rightarrow$ 后验加权发射描述子软分配得区制后验 $\rightarrow$ 计算预期剩余久期与后验熵 $\rightarrow$ 经 3.7 映射得目标仓位 w_t 。该步无需重训，毫秒级完成，可解释、可审计。

5.3 实盘执行

执行标的：中证 800 无专属股指期货（场内仅 **IF/IC/IH/IM**），实务三选一——(1) 中证 800 **ETF**；(2) 沪深 300 **ETF** + 中证 500 **ETF** 按成分权重复制（中证 800 $\approx$ 300+500）；(3) **IF+IC** 期货组合复制（便于做空、加杠杆、占用低，适合择时叠加）。 w_t 即配置于上述工具的比例，余额配现金/货币/短债。

事件驱动调仓（对应 **RebalanceEngine**）：每日计算目标仓位，仅当 $|w_t - w_{\text{cur}}| > \delta$ 、或变点概率越阈、或区制 **MAP** 翻转时生成订单，次日开盘执行（防前视）。结果为多数交易日不动、调仓集中于区制切换附近。

5.4 更新节奏

在线滤波（BOCPD/HSMM 递归）逐日进行、无需重训；超参（久期、发射先验、 K ）季度滚动重估；结构（区制数、久期族、特征集、映射形式）年度重搜。总原则：在线滤波每日、参数季度、结构年度。

六、回测框架与统计检验

6.1 防泄漏

一律前向滚动（walk-forward）；因子/标签层面采用 **Purged K-Fold + Embargo**——因预测期跨多日，须剔除与测试期信息重叠的样本并设隔离带，杜绝变相泄题。

6.2 评估口径

年化收益、夏普比率、Calmar、最大回撤、换手率、调仓频次分布（验证“非定频”）、以及分区制绩效（牛/熊/震荡/危机）。择时模型尤须报告检测滞后（断点后反应时滞）以客观刻画其短板。

6.3 统计去伪

结论须通过 **Deflated Sharpe Ratio**（按尝试配置数折减选择效应）与 **BH-FDR**（多重检验校正），并经多窗口/多种子稳健性检验，防止“单条曲线显著”的过拟合假象。

6.4 前视偏差对照实验

将同一 HMM 分别以平滑（含未来信息）与滤波（严格因果）两种模式运行，二者绩效之差即前视偏差幅度；BOCPD 天然为滤波形态。该对照正面坐实“主流离线 HMM 择时绩效部分源于前视、而本框架因果稳健”的核心主张。

6.5 方法论流程验证（合成区制数据，示例）

为验证完整链路（数据 → 离线估参 → 在线因果推理 → 仓位 → 回测）的正确性，本文在合成的牛/震荡/熊三区制数据上运行终版引擎（图表 3）。结果显示：相较恒定满仓，引擎将最大回撤由约 -63% 压低至约 -16%，且仅约 21% 的交易日发生实际调仓，直观印证其“控回撤、低换手、事件驱动”的设计目标。

说明：上述为基于合成数据的流程正确性验证，旨在证明工程链路机制行为符合预期，不代表中证 800 真实历史绩效。基于真实中证 800 数据、按本文 walk-forward 与统计去伪框架的完整实证，为后续研究内容。

图表 3：合成区制数据上的终版引擎表现（流程验证）

净值：引擎曲线显著平滑于买入持有，回撤大幅收敛

仓位：随区制切换分段调整，区间 $[0, 1]$

下轨：变点概率与区制序列，调仓集中于切换附近

（详见配套 engine_demo.png）

七、客户应用

量化客户：直接取连续仓位序列 $\{w_t\}$ 作为指数/行业敞口管理信号，或作为多策略组合的择时叠加层；多指数并行版可输出差异化配置向量。

基金研究客户：取引擎每日输出的 (区制 **MAP**, 区制后验, 变点概率, 预期剩余久期), 组装为市场状态叙事——“当前处于 **X** 区制, 已存续 **N** 个交易日, 预期剩余约 **M** 日, 区制切换后验概率 **P%**”, 服务于宏观择时观点与风险预警。

八、总结与展望

本文构建了一套以 **BOCPD + HSMM** 为内核的全天候、事件驱动指数仓位择时框架, 理论自治、严格因果、工程轻量, 并给出了由基线到终版的五级消融式优化路径与完整的回测—去伪框架。其方法论定位为贝叶斯概率状态机, 而非深度学习或强化学习。

后续可拓展方向: (1) 以完整 **EDHMM-EM / HDP-HSMM** 替代久期的实用近似, 提升久期估计严谨度; (2) 以 **Student-t / NIW** 多元发射增强尾部与协同刻画; (3) 在本因果引擎之上叠加强化学习超结构 (以引擎为强基线 + **KL-to-prior** 正则), 学习引擎之外的残差择时; (4) 将本引擎与深度波动率目标、临界预警、动态 **CPPI** 组装为完整全天候系统 (引擎为状态脊柱)。

九、风险提示

本报告为金融工程方法论研究, 所述模型与框架基于历史数据与统计假设构建, 存在以下风险: (1) 模型失效风险——市场结构发生根本性变化时, 历史区制规律可能不再适用; (2) 区制识别滞后——变点检测在统计确认区制切换时, 行情可能已部分演绎, 构成绩效上限; (3) 参数与设定敏感性——久期分布、发射先验、区制数等设定的误差可能影响结果稳健性; (4) 过拟合风险——多次尝试下的“显著”结果可能含运气成分, 须经 **Deflated Sharpe** 等检验; (5) 执行风险——实盘存在交易成本、冲击成本、流动性与跟踪误差。本报告不构成任何投资建议, 据此操作风险自担。